Universidad Central de Venezuela

Facultad de Ciencias Económicas y Sociales
Escuela de Estadistica y Ciencias Actuariales

Análisis Descriptivo de los Factores Determinantes en ciclos agrícolas

Trabajo: Informe Académico

Computación I

AUTOR:

Joshua Santeliz
Emily Gallardo

PROFESOR:
Jesus Ochoa
Oliver Triveño

Caracas, Febrero 2026

Índice general

Resumen III

1. Planteamiento del Problema 3
1.1. Justificación . . . 4
1.2. Objetivos . . . 4
1.2.1. Objetivo General . . . 4
1.2.2. Objetivos Específicos . . . 4
1.3. Cobertura . . . 4
1.3.1. Horizontal . . . 4
1.3.2. Vertical . . . 5
1.4. Periodo de Referencia . . . 5
1.5. Variables . . . 5

2. Marco Teórico 7
2.1. Bases Teóricas . . . 7
2.1.1. Análisis Exploratorio de Datos (EDA) . . . 7
2.1.2. Cocientes estadísticos: . . . 7
2.1.3. Medidas de Posición: . . . 8
2.1.4. Medidas Tendencia Central: . . . 8
2.1.5. Medidas de dispersión: . . . 9
2.1.6. Medidas de Forma: . . . 10

3. Marco Metódico 11
3.1. Bases metódicas utilizadas en el trabajo de investigación . . . 11
3.1.1. Item 1 . . . 11
3.1.2. Item 2 . . . 11
3.1.2.1. Item 2.2 . . . 11
3.1.3. Item n . . . 12

4. Análisis de Resultados 13
4.1. Presentación de resultados 1 . . . 13
4.2. Presentación de resultados 2 . . . 13
4.3. Presentación de resultados n . . . 13

5. Conclusiones y Recomendaciones **14**

A. Anexo A **15**

B. Anexo B **16**

C. Anexo C **17**

Resumen

En el presente informe se realiza un análisis exploratorio de los datos de influencias en los cultivos en el territorio de la India, tomando en cuenta registros desde 2010 hasta 2020. Es un informe que tiene como propósito responder a la incertidumbre que enfrentan los ciclos agrícolas al ser afectados ya sea positivamente o negativamente por factores como los agroquímicos y la precipitación anual, esto en un determinado espacio de tierra. Se usan métodos estadísticos descriptivos (como el uso de medidas de tendencia central, cocientes estadísticos entre otros conceptos) con el fin de medir dicha incertidumbre por mediante el uso de indicadores de dispersión, estos indicadores son: la desviación típica, los rangos y el coeficiente de variación. También nos apoyaremos en estadísticas bivariantes con el fin de comprender las relaciones lineales entre variables, utilizando Covarianza y coeficiente de correlación para observar su fuerza de influencia. Además, se examinan las tendencias históricas aplicando las medidas de forma, observando su distribución y concentración de los datos. Por último, analizaremos el desempeño de producción por temporadas (Kharif, Zaid, Rabi), aplicando técnicas estadísticas descriptivas y visualización de datos con R.

Introducción

La industria agrícola ha experimentado a lo largo del tiempo una dependencia importante a las temporadas de cultivo, siendo esta una de las cosas en el cual la industria ha tenido considerables inversiones, por ejemplo, en la Ciencia y tecnología. La ciencia es un ámbito que ofrece alternativas basadas en datos, una de ellas es el análisis de datos y el uso de la estadística aplicada a la agricultura. Comunicando una comprensión a las temporadas de cultivo a fin de aplicar inversiones acertadas y competentes que favorezcan a las producciones. Siguiendo esta idea entonces debemos responder a la incertidumbre de como gestionar las temporadas de cultivos para obtener resultados óptimos. Lo que se vuelve fundamental comprender factores determinantes que afecten a los ciclos agrícolas. Algunos de ellos son el clima y los agroquímicos (fertilizantes y pesticidas).

Para el profesional en Ciencias Estadísticas y Ciencia de Datos, este sector presenta un desafío fascinante: ¿Es posible modelar la incertidumbre en temporadas de cultivo? ¿Existen patrones que le permitan a las industrias entender los ciclos agrícolas?, bueno en este informe trataremos de implementarlo y descubrir esos patrones de una manera básica pero eficaz, la cual podrá entender sin necesidad de conocimientos o conceptos complejos en Estadística.

El presente trabajo de investigación tiene como propósito realizar un análisis estadístico exhaustivo sobre el conjunto de datos" Agricultural Crop Yield in Indian States Dataset", el cual abarca más de 19,000 registros de cultivos desde 1997 hasta 2020. A través del uso de herramientas computacionales avanzadas en R y técnicas de visualización de datos, se busca descomponer la varianza de los cultivos en función de factores críticos como el Clima, los Fertilizantes y los Pesticidas.

Estructura del Informe

Este documento técnico se encuentra estructurado en cinco capítulos fundamentales:

- En el **Capítulo I**, se plantea la problemática de no comprender las influencias en los ciclos agrícolas, formulando las preguntas de investigación y delimitando el alcance temporal y geográfico del estudio.

- El **Capítulo II** establece el Marco Téorico, definiendo los conceptos estadísticos clave como las medidas de tendencia central, medidas de dispersión y correlación, necesarios para la interpretación de los datos.
- El **Capítulo III** describe el Marco Metodológico, detallando el proceso de limpieza de datos (ETL), las pruebas de hipótesis y los algoritmos utilizados para validar la calidad de la información.
- El **Capítulo IV** presenta el Análisis de Resultados, donde se exhiben las tablas y gráficos generados dinámicamente, discutiendo los hallazgos sobre la variabilidad de los ciclos agrícolas y la dinámica temporal.
- Finalmente, en el **Capítulo V**, se exponen las Conclusiones y Recomendaciones estratégicas derivadas del análisis cuantitativo, orientadas a la toma de decisiones basada en datos (*Data-Driven Decision Making*).

Capítulo 1

Planteamiento del Problema

En el mundo agrícola hay muchos temas por tratar, desde la salud nutricional hasta la gastronomía industrial, siendo temas de vital importancia para la vida humana. En este estudio nos vamos a ubicar en la agricultura de la India en el ámbito del cultivo, resaltando que una gestión eficiente de las temporadas de cultivo no solo garantiza cosechas óptimas, sino que genera seguridad alimentaria y eleva la calidad de vida de las personas.

Analizaremos específicamente las temporadas de cultivo y como estas son influenciadas por distintos factores como el clima y los agroquímicos. Estas influencias son de gran interés para las empresas ya que una descripción de las mismas, servirían de referencia para mejorar su gestión de inversión.

Por lo antes mencionado surgen problemas por ejemplo a la hora de saber que cantidad de agroquímicos aplicar a un área en específico y en cierta estación de cultivos y también no saber el nivel de precipitación que tendremos en un año, lo cual puede ser determinante para prepararse en los ciclos de cultivo en dicho año.

Estos problemas se resuelven luego de modelar esta investigación donde podremos comprender mejor la situación y se recomendará posibles decisiones a tomar. Teniendo en cuenta esto surgen las siguientes preguntas de investigación:

1. ¿De qué manera influyen la cantidad de agroquímicos en los ciclos de cultivos?

2. ¿Por qué son necesario los fertilizantes y los pesticidas en una temporada de cultivo?

3. ¿Cuáles son las precipitaciones anuales que favorecen a las temporadas de cultivo?

4. ¿La cantidad de agroquímicos varía según los niveles de precipitación?

1.1. Justificación

La justificación de este trabajo de investigación reside en la necesidad de aplicar técnicas estadísticas rigurosas y herramientas de software como R y Python para mitigar la incertidumbre de sembrar los cultivos en el sector agrícola de la India.

Desde el punto de vista práctico, los resultados permitirán a las Industrias tomar decisiones basadas en datos (Data-Driven Decisions) sobre que materiales invertir o en qué temporada del año se debe desarrollar. Con una metodología replicable utilizando R y LaTeX para el análisis exploratorio y descriptivo de grandes volúmenes de datos.

1.2. Objetivos

1.2.1. Objetivo General

- Realizar un análisis estadístico descriptivo de datos de cultivos en diferentes temporadas de la India durante el período 2010-2020. para identificar y describir las características más influyentes en las temporadas de cultivos.

1.2.2. Objetivos Específicos

- Analizar la variabilidad pluviométrica mediante el uso de indicadores estadísticos, con el fin de determinar una óptima gestión del recurso hídrico.
- Observar la distribución de los factores que afectan a los cultivos por temporada del año.
- Categorizar temporadas de mayor y menor demanda tanto de pesticidas como de fertilizantes.

1.3. Cobertura

1.3.1. Horizontal

La cobertura horizontal abarca las características de cada cultivo registrado, donde se consideran las dimensiones descriptivas del cultivo y las métricas de influencia agrícola.

1.3.2. Vertical

La cobertura vertical del trabajo de investigación abarca un total de *9,884* observaciones (registros) donde cada fila representa un cultivo obtenido en la India con sus características correspondientes, con un alcance temporal que abarca desde el año 2010 hasta el año 2020. (Estos registros son previos al ETL)

Tabla 1.1: Variables consideradas

TIPO	VARIABLE	DESCRIPCIÓN
Categórica	Crop	Nombre del cultivo
Categórica	Season	Temporada que se cultiva
Numérica	Annual_Rainfall	Precipitación anual
Numérica	Crop_Year	Año que se cultivo (2010-2020)
Numérica	Fertilizer	Fertilizante utilizado en los cultivos (kg)
Numérica	Pesticide	Pesticida utilizado en los cultivos (kg)
Numérica	Area	Superficie de la tierra en hectáreas
Numérica	Production	Producción en toneladas metricas
Numérica	Yield	Rendimiento de producción

1.4. Periodo de Referencia

La fuente de datos a estudiar corresponde al repositorio abierto de Kaggle ("Agricultural Crop Yield in Indian States Dataset"). Donde se toma como período de referencia los registros pertenecientes al intervalo de tiempo 2010-2020, donde la consistencia de los datos es mayor entre los años 2017-2019 (previo a al ETL), El procesamiento de la información se realizó con corte a febrero de 2026.

1.5. Variables

La variable principal en estudio (Variable Dependiente/Objetivo) es Season, que representan las Temporadas de cultivo, medido en 3 estaciones "Kharif" (Otoño), "Zaid" (Verano corto) y "Rabi" (Invierno) ,siendo las principales temporadas de cultivo en la India

Como variables explicativas o independientes se analizan:

1. Variables Temporales: **Crop year.**
2. Variables Categóricas: **Crop**

3. Variables Influyentes: **Annual_Rainfall , Fertilizer y Pesticide .**
4. Variable Geográfica: **Area**
5. Variables Explicativas: **Area , Yield y Production.**

Capítulo 2

Marco Teórico

2.1. Bases Teóricas

El presente capítulo establece los fundamentos matemáticos y estadísticos necesarios para el análisis de los datos de influencia en ciclos agrícolas. Se aborda la teoría desde una perspectiva descriptiva, priorizando la caracterización de la distribución de los ciclos agrícolas (variable independiente) y la identificación de patrones a lo largo del tiempo.

La comprensión de estos conceptos es crucial para interpretar correctamente las variables influyentes como el Annual_Rainfall , Fertilizer y Pesticide . Las cuales se compararan con las variables explicativas Area , Yield y Production. para dar resultados y recomendaciones confiables.

2.1.1. Análisis Exploratorio de Datos (EDA)

El Análisis Exploratorio de Datos, formalizado por John Tukey, es el paso preliminar crítico en cualquier estudio de ciencia de datos. Su objetivo es resumir las características principales de un conjunto de datos, a menudo con métodos visuales, sin formular hipótesis a priori.
En el contexto de este trabajo, el EDA permitirá detectar *outliers* nulos y mal categorizados (estaciones repetidas) y verificar si la distribución de las variables influyentes sigue una distribución parecida a la de la variable independiente (Season).

2.1.2. Cocientes estadísticos:

Los cocientes estadísticos son la razón, la proporción, el porcentaje, las tasas entre otros. El cociente me dice que cantidad del denominador este contenido en el numerador, Fueron desarrollados por Gaspar Neumann y Edmund Halley. Es importante para

nuestro estudio porque tomaremos conceptos como la razón, tasas para comparar las relaciones de nuestras variables influyentes en los ciclos agrícolas.

Razón: Es cuando existe una relación cuantitativa entre 2 cantidades que comparten el mismo total. Fue Karl Pearson, Francis Galton pioneros en el desarrollo de este concepto. Tomaremos este concepto importante para comprender la relación cuantitativa entre las variables *Pesticide* y *Fertilizer* en las temporadas de cultivos.

Tasas: Son razones dinámicas porque transcurren en el tiempo y se multiplican generalmente por 1000. John Graunt y figuras posteriores como Bayes o Bernoulli la continuaron desarrollándola. La usaremos para saber la cantidad de agroquímicos en un determinado año.

2.1.3. Medidas de Posición:

Son medidas que ayudan a ubicar los datos fácilmente. Están constituidas principalmente por cuartiles, deciles y percentiles. Estos dividen el conjunto de datos en distintas partes, dividiendo los cuartiles en 4 partes iguales, los de deciles en partes iguales de 10 y los percentiles dividiendo en 100 partes iguales. Para nuestro informe se usará para obtener indicadores importantes que nos ayudaran a analizar las distribuciones de los datos apoyando a responder preguntas de investigación y objetivos planteados. También este concepto se usa en el Análisis Exploratorio de Datos (EDA). Thomas Bayes, Jakob Bernoulli, Pafnuti Chebyshev y Francis Galton fueron los pioneros desarrollando este tema.

2.1.4. Medidas Tendencia Central:

Son medidas ubicadas en el centro de la distribución. Denominados promedios y se dividen en dos tipos los matemáticos y los no matemáticos. Enfocando este tema al estudio es de importancia ya que estas medidas nos permiten comprender las tendencias de equilibrio a esperar en los datos. Los autores principales que desarrollaron este tema fueron: Gauss, Karl Pearson y Cournot.

Media Aritmética: Es la representación de los datos manteniendo un equilibrio en toda la serie de datos, esta definición es importantísima para la estadística ya que es un valor que agrupa un conjunto de datos, en el contexto de nuestro estudio es fundamental para responder a lo planteado. Carl Friedrich Gauss y Adrien-Marie Legendre desarrolladores de esta importante medida.

Mediana: Es el valor que ocupa la posición central de un conjunto de datos ordenado. Centrado en nuestro estudio es relevante ya que nos permite obtener un indicador más robusto a valores atípicos es decir una medida más representativa. Antoine Augustin Cournot y Francis Galton fueron pioneros en esta definición.

Moda: Es el valor que aparece con mayor frecuencia en el conjunto de datos. Orientado en el informe es de interés ya que nos dictara la mayor frecuencia de los datos, indicando que ese dato es importante ya que dirá una representación de lo común. Karl Pearson fue el principal desarrollador de la moda donde se basó en una idea de que siempre destacaba un dato ante los demás por ser el más común.

Media Geométrica: La media geométrica es igual a la raíz n-esima del producto de n valores positivos, es decir multiplica los valores a diferencia de la media aritmética, lo que es ideal cuando se desea saber el promedio del tanto por ciento o disminución de una cosa. Desde épocas de Pitágoras hasta las bases firmes de Irving Fisher esta medida ha llevado contribuciones a lo largo del tiempo. Llegando a ser una alternativa excelente cuando la media no es lo indicado.

Media Armónica: Se denota H y se obtiene como los recíprocos de una serie dada, luego se determina la media aritmética de dichos recíprocos, y se toma la inversa de dicha media como la media armónica. Situando este concepto en el análisis de la influencia a los ciclos agrícolas es válido ya que promedia cantidades de químicos aplicados en una hectárea en específico. Desde épocas de Archytas de Tarento hasta Isaac Newton y Gottfried Leibniz se desarrolló inicialmente este concepto, basándose un poco en la música y en la física.

2.1.5. Medidas de dispersión:

Son medidas que buscan saber la variabilidad con respecto los valores centrales, dividiéndose en absolutas y relativas. Considerándola en la investigación presenta una notaría importancia ya que la influencia depende mucho de la dispersión de los factores. Abraham de Moivre Carl Friedrich Gauss , Francis Galton , Karl Pearson Ronald A. Fisher desarrolladores de estas medidas.

Rango: Es el recorrido del conjunto de valores, expresado como la diferencia entre el Valor Máximo y el Valor Mínimo de la serie. Representando la mayor diferencia en los datos, pertenece a las familias de las absolutas. Implementada al informe es crucial para entender la diferencia entre los datos. Es una de las medidas más antiguos ya que es intuitiva y fácil de entender por ello se ha aplicado desde casi siempre. Uno de los primeros fue Hiparco de Nicea.

Rango intercuartílico: Es igual a la diferencia entre el tercer cuartil y el primer cuartil. Lo que quiere decir que nos queda el 50 % central de los datos. siendo fundamental para la obtención de resultados robusto no propensos a valores atípicos. Desarrollado por Francis Galton un principal autor del concepto.

Desviación Media: Es el promedio de las distancias entre los valores de la serie y la medida de tendencia central escogida. Interesante para esperar una dispersión entre los datos a estudiar. Roger Cotes estudio esta medida para que comenzara ha definirse.

Varianza (Volatilidad): Mide la dispersión de las precipitaciones respecto a la media, fundamental para medir el riesgo de precipitación en un año. Ronald A. Fisher formalmente introdujo el tema de la varianza.

Desviación estándar: Es la raíz cuadrada positiva de la varianza. Constituye el índice de dispersión más usado y confiable. Resaltando la dispersión entre las variables influyentes de nuestro estudio. Karl Pearson para muchos el más influyente en las medidas de dispersión.

Coeficiente de variación: Pertenece a las medidas relativas, siendo así una medida que nos dice el porcentaje de deviación, existe varios coeficientes de variación, pero el más famoso es el de Pearson. Fundamental para comparar medias e indicadores de interés para el informe. Karl Pearson sin duda unos de los principales autores en las medidas relativas.

Regla Empírica: usado de forma gráfica para ver el comportamiento y desviaciones de los datos con respecto a la distribución. Aplicado en el estudio para la identificación de valores atípicos. Abraham de Moivre y Carl Friedrich Gauss.

2.1.6. Medidas de Forma:

Son indicadores que nos dicen como se distribuyen los datos, teniendo una ventaja de que no necesariamente hay que graficar para observar las distribuciones. Luego de comprender los que es la simetría y la asimetría estos indicadores son importantes ya que nos permiten ver si hay alguna existencia de sesgo en los datos. William Gosset, Francis Galton Ronald A. Fisher, desarrolladores de estas medidas.

Asimetría: Es cuando los datos se presentan en una distribución desproporcionada a cualquier lado de la media aritmética. Las medidas de asimetría son indicadores que nos dicen si la cola de la distribución es sesgada a la izquierda (negativa) o a la derecha (positiva), llevándolo a el análisis de influencia en las temporadas de cultivos, permitirá observar la tendencia de los datos sirviendo de sustentos para las respuestas. Pearson Galton y Fisher precursores de este tema.

Kurtosis: Medida estadística utilizada para determinar cuán puntiaguda es la distribución de una serie de datos tomando como referencia la curva normal. Clasificándose de la siguiente manera: Leptocúrtica, Mesocúrtica y Platicúrtica, evidenciando una concentración de los datos alrededor del valor máximo de la curva. Existiendo distintos coeficientes para acertar mejor al objetivo plateado. Karl Pearson principal desarrollador de la definición.

Capítulo 3

Marco Metódico

En esta sección se presentan las metodologías y/o test necesarios relacionados con la práctica divulgada en el marco teórico, así como las fuentes de datos.

3.1. Bases metódicas utilizadas en el trabajo de investigación

Desarrollo

3.1.1. Item 1

Descripción

3.1.2. Item 2

Descripción

3.1.2.1. Item 2.2

Descripción

3.1.3. Item n

Descripción

Capítulo 4

Análisis de Resultados

{Este capítulo presenta los resultados obtenidos al aplicar las metodologías descritas en el capítulo anterior, así como del análisis estadístico descriptivo de las variables estudiadas y las ventajas y desventajas al aplicar dichos tests.}

4.1. Presentación de resultados 1

Descripción

4.2. Presentación de resultados 2

Descripción

4.3. Presentación de resultados n

Descripción

Capítulo 5

Conclusiones y Recomendaciones

1.- Conclusion 1 del trabajo de investigación.

Recomendación Recomendación 1 del trabajo de investigación.

2.- Conclusion 2 del trabajo de investigación.

Recomendación Recomendación 2 del trabajo de investigación.

n.- Conclusion n del trabajo de investigación.

Recomendación Recomendación n del trabajo de investigación.

Apéndice A

Anexo A

Apéndice B

Anexo B

Apéndice C

Anexo C